# Pronóstico de ventas reales del comercio minorista en Colombia

Johan David Perdomo Campos

Pontificia Universidad Javeriana Cali - Clase: Análisis de Series de Tiempo

- Presentación
- 1 Propuesta (Unidad 1)
- 2 Los datos
- 3 Promedio móvil
- 4 Rezagos
  - 4.1 Gráfico de rezagos
  - 4.2 Autocorrelación
- 5 Estacionalidad
  - 5.1 Gráfico estacional
  - 5.2 Subseries por mes
  - 5.3 Descomposición
- 6 Transformación de la serie
  - 6.1 ¿Hace falta transformar?
  - 6.2 ¿Por qué logaritmo y no otra transformación?
- 7 Descomposición
- 8 Estacionariedad y diferenciación
  - 8.1 Cómo se comprueba
  - 8.2 Paso 1: la serie en logaritmos
  - 8.3 Paso 2: diferencia estacional
  - 8.4 Paso 3: diferencia regular
  - 8.5 Resumen del procedimiento
- 9 Suavizamiento exponencial y Holt-Winters
  - 9.1 Procedimiento
  - 9.2 Entrenamiento y prueba
  - 9.3 Modelos
  - 9.4 Comparación
  - 9.5 Modelo elegido
  - 9.6 Pronóstico
- 10 Conclusiones
- Fuentes

# Presentación

Este documento reúne los entregables del curso Análisis de Series de Tiempo. La serie de trabajo es el índice mensual de ventas reales del comercio minorista en Colombia, publicado por el DANE en la Encuesta Mensual de Comercio (EMC).

- Unidad 1: propuesta (capítulo 1).
- Unidad 2: promedio móvil, rezagos y estacionalidad (capítulos 2 a 5).
- Unidad 3: transformación, descomposición, estacionariedad y diferenciación (capítulos 6 a 8).
- Unidad 4: suavizamiento exponencial y Holt-Winters (capítulo 9).
- Conclusiones de las unidades 2 a 4 (capítulo 10).

Código y datos: https://github.com/johancampos13/Ana-lisisSeriesTiempo (https://github.com/johancampos13/Ana-lisisSeriesTiempo)

# 1 Propuesta (Unidad 1)

El proyecto analiza y pronostica el índice nacional mensual de ventas reales del comercio minorista en Colombia, publicado por el DANE en la Encuesta Mensual de Comercio (EMC). Se estudian su tendencia y su estacionalidad, y al final del curso se harán pronósticos de hasta doce meses.

La pregunta es qué modelo de series de tiempo pronostica mejor este índice. Se compararán un modelo ingenuo estacional, suavizamiento exponencial (ETS) y ARIMA, dejando los últimos meses como periodo de prueba.

Pronosticar las ventas sirve para planear inventarios y recursos. En el boletín de la EMC de agosto de 2026, el DANE reportó un crecimiento anual provisional de 7,3 % en las ventas reales del comercio minorista y vehículos.

Los datos son públicos y no incluyen información personal ni de una empresa específica, así que no se requiere autorización. Los términos de uso del DANE permiten usar y transformar la información citando la fuente: “Fuente: Departamento Administrativo Nacional de Estadística: www.dane.gov.co”.

# 2 Los datos

Se usa el anexo de índices empalmados de la EMC de agosto de 2026 (hoja 1.2, ventas en valores reales, base 2019 = 100). La variable es “Total comercio minorista sin otros vehículos”, que según el DANE es el total comparable en toda la serie. Va de enero de 2013 a agosto de 2026 (164 meses).

El script `R/preparar_datos.R` extrae esa columna del Excel y la guarda en un CSV. Aquí se lee y se convierte en serie de tiempo mensual:

```
datos <- read.csv("datos/ventas_reales_minorista.csv")
y <- ts(datos$indice_ventas_reales, start = c(2013, 1), frequency = 12)
```

```
autoplot(y) + labs(x = "Año", y = "Índice")
```

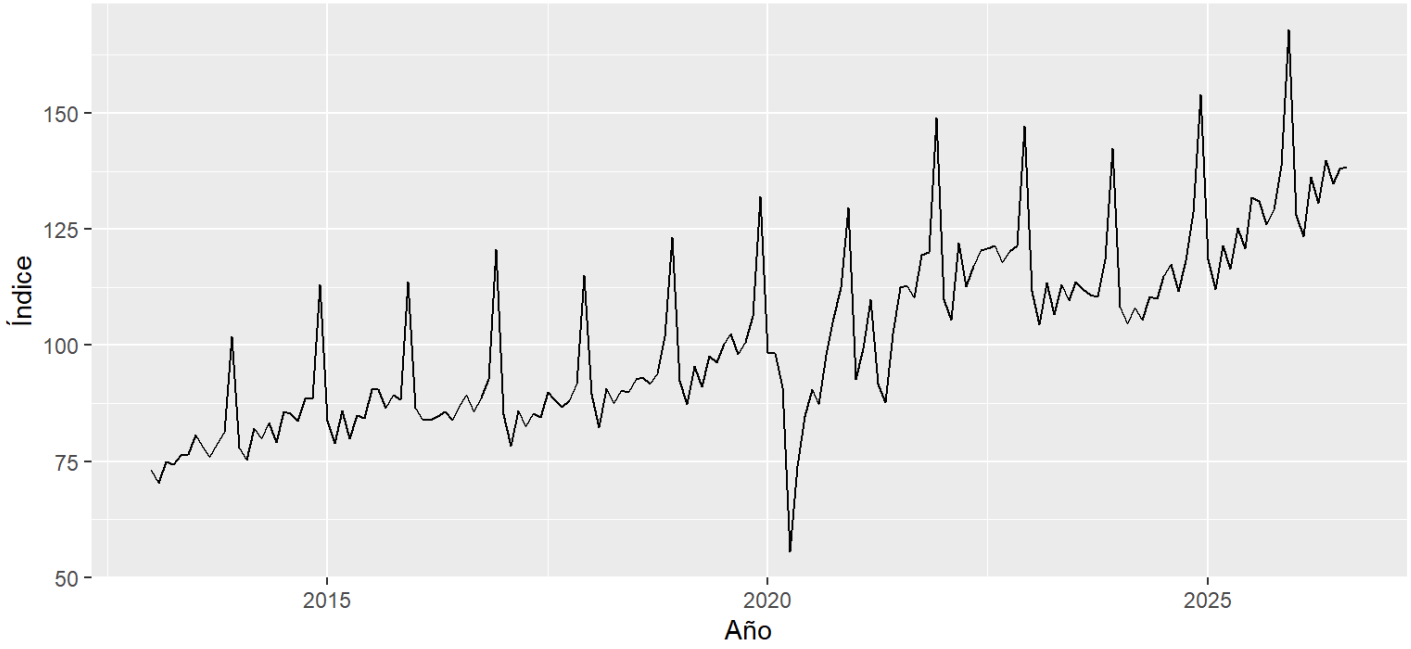



Figura 2.1: Índice de ventas reales del comercio minorista (2019 = 100).

En la Figura 2.1 se ve que el índice crece en el tiempo (de 78,5 en promedio en 2013 a 128,3 en 2025) y que todos los años hay un pico en diciembre. También se ven dos momentos atípicos: la caída de abril de 2020 por la cuarentena del COVID-19 (55,5, el valor más bajo de la serie) y la baja de 2023.

# 3 Promedio móvil

Un promedio móvil de orden *m* reemplaza cada mes por el promedio de los *m* meses alrededor de él. Así se suavizan las subidas y bajadas de corto plazo y se ve mejor la tendencia. Si el orden es 12, el promedio incluye un año completo y la estacionalidad se cancela.

Se calculan promedios de orden 3, 6 y 12 con la función `ma()`:

```
autoplot(y, series = "Original") +
  autolayer(ma(y, 3), series = "MA 3") +
  autolayer(ma(y, 6), series = "MA 6") +
  autolayer(ma(y, 12), series = "MA 12") +
  scale_colour_manual(values = c(Original = "grey70", "MA 3" = "orange",
                                 "MA 6" = "steelblue", "MA 12" = "darkred")) +
  labs(x = "Año", y = "Índice", colour = "")
```




Figura 3.1: Serie original y promedios móviles de orden 3, 6 y 12.

En la Figura 3.1 el promedio de orden 3 todavía sigue los picos de diciembre y el de orden 6 sigue ondulando cada año. El de orden 12 ya no tiene esos picos, lo que confirma que el ciclo estacional dura 12 meses.

La línea del promedio de orden 12 muestra la tendencia de la serie y sus ciclos:

- 2013 a 2019: crecimiento constante.
- 2020: caída por la pandemia.
- 2021 y 2022: recuperación por encima del nivel de 2019.
- 2023: caída (el promedio anual pasó de 119,7 a 113,9).
- 2024 a 2026: nueva subida.

# 4 Rezagos

Un rezago es el valor de la serie *k* meses antes. Comparar cada mes con sus rezagos muestra qué tanto depende el índice de lo que pasó antes. La función de autocorrelación (ACF) mide esa relación para cada rezago.

# 4.1 Gráfico de rezagos

```
gglagplot(y, lags = 12, do.lines = FALSE) + guides(colour = guide_legend(title = "Mes"))
```

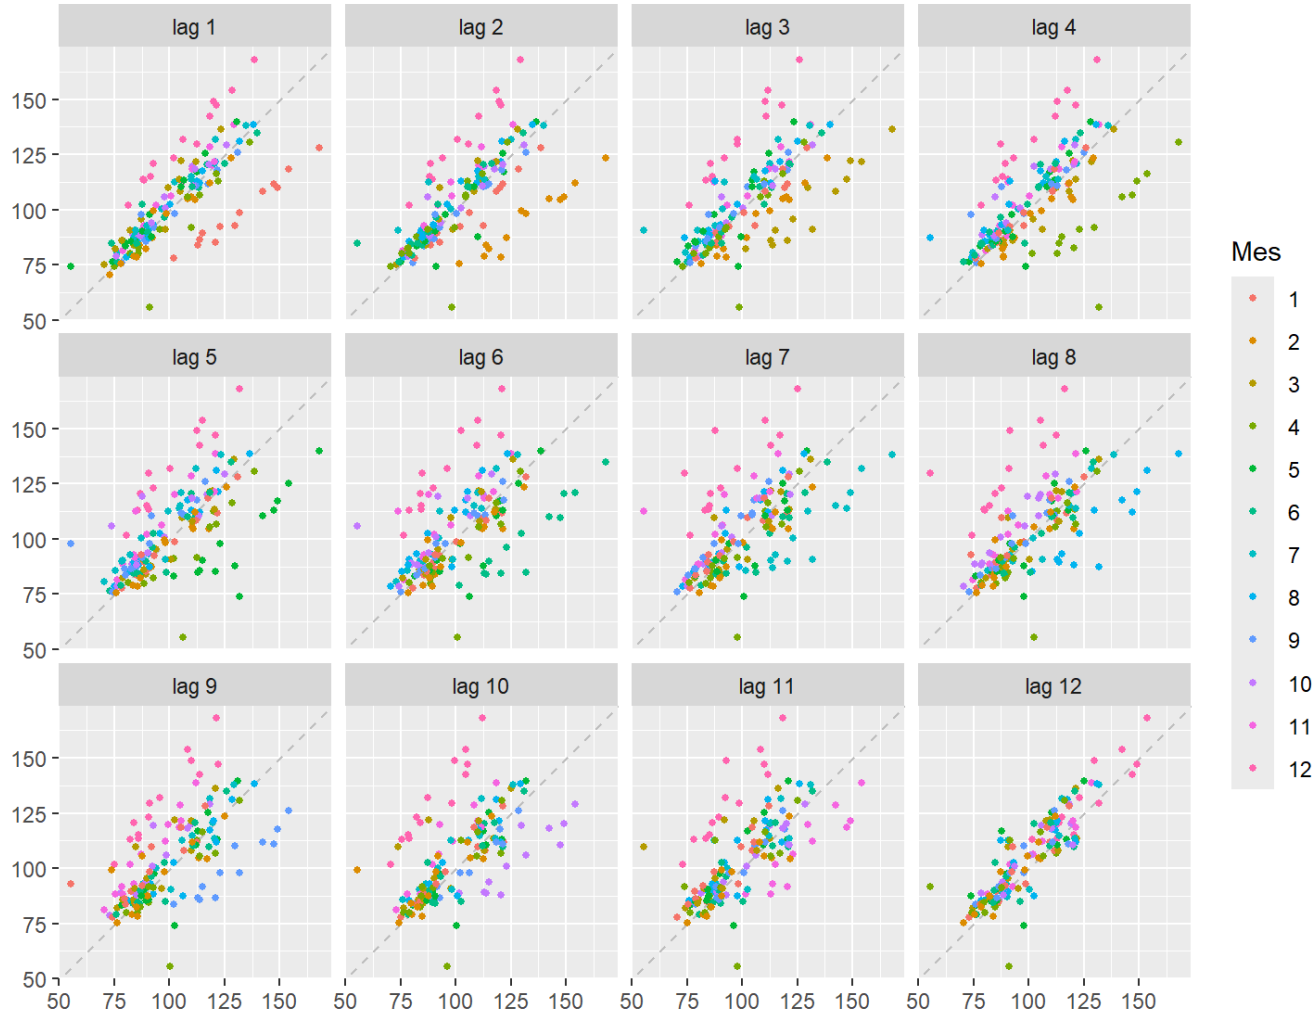



Figura 4.1: Índice de cada mes frente a su valor 1 a 12 meses antes.

En la Figura 4.1 los puntos de diciembre quedan siempre por encima de la diagonal en los rezagos 1 a 11, porque diciembre vende más que los demás meses. En el rezago 12 los puntos casi forman una línea: cada mes se parece mucho al mismo mes del año anterior.

# 4.2 Autocorrelación

```
ggAcf(y, lag.max = 36) + labs(title = "")
```

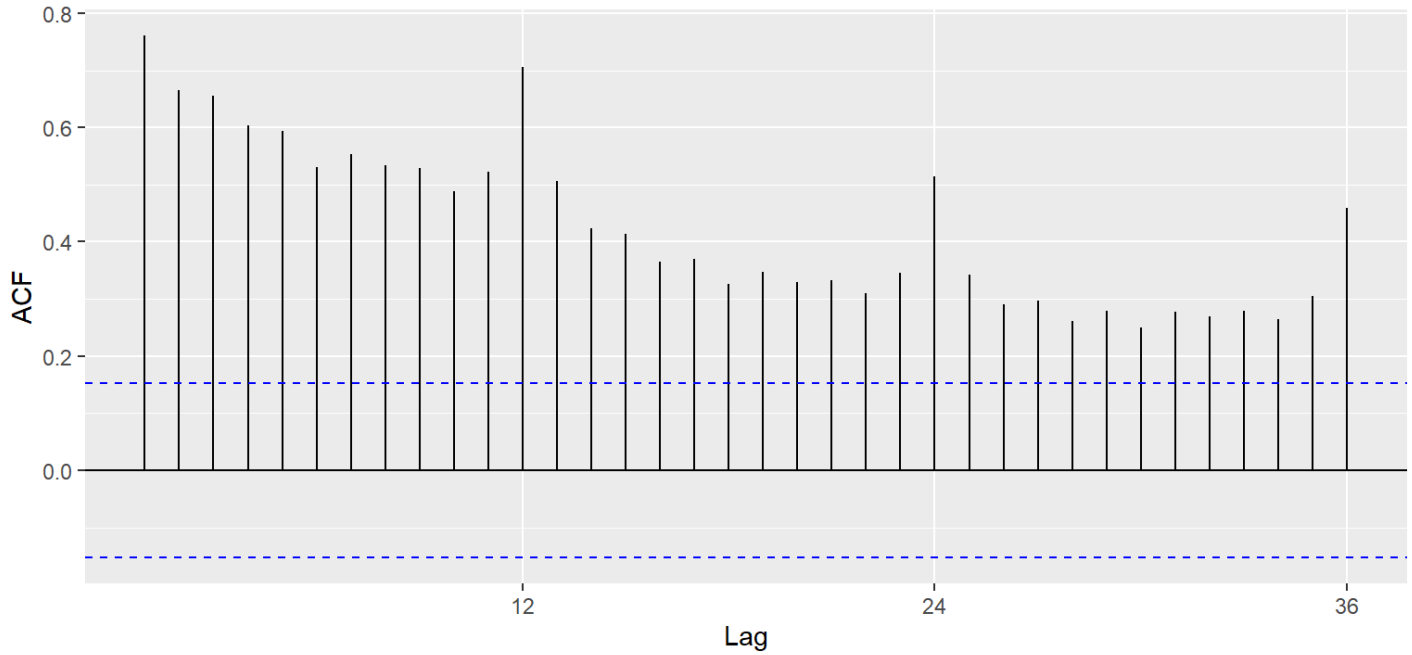



Figura 4.2: ACF del índice.

La ACF de la Figura 4.2 baja lentamente (0,76 en el rezago 1), lo que indica que la serie tiene tendencia. Además tiene picos en los rezagos 12, 24 y 36, que corresponden a la estacionalidad anual.

Para quitar la tendencia se toma la primera diferencia (cambio de un mes a otro):

```
ggAcf(diff(y), lag.max = 36) + labs(title = "")
```

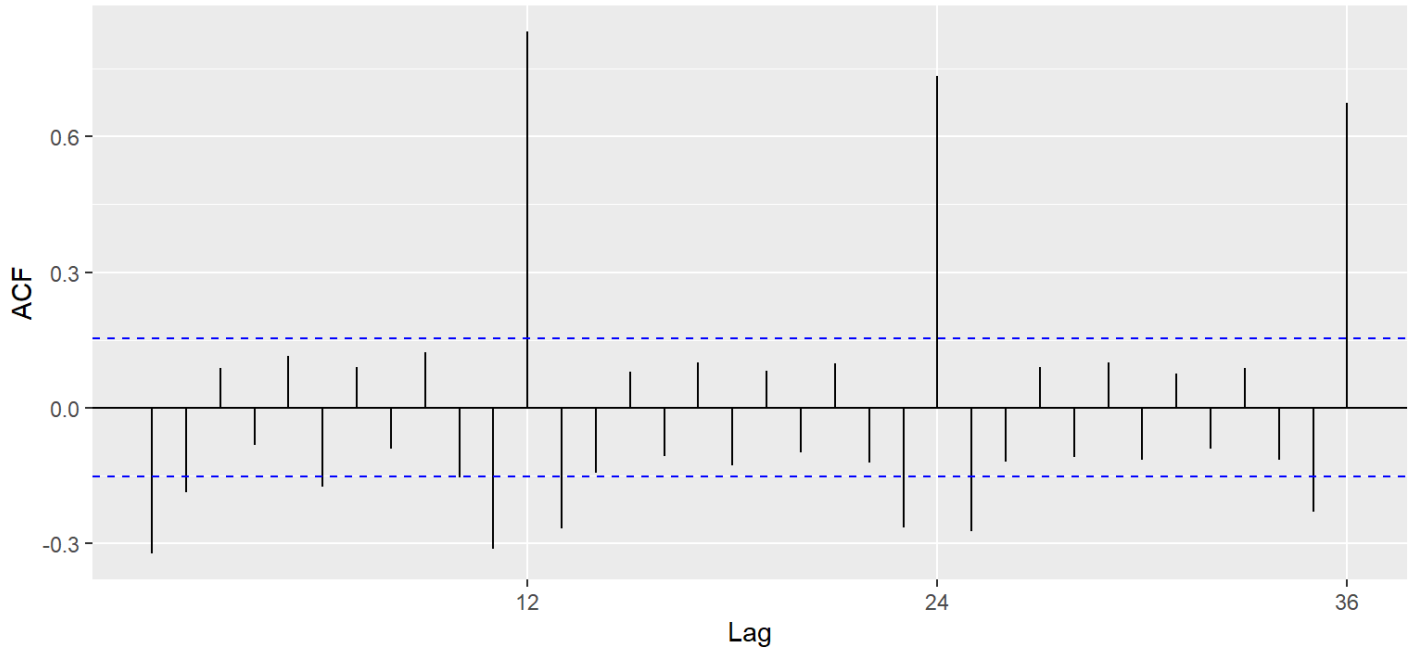



Figura 4.3: ACF de la primera diferencia del índice.

Sin la tendencia, la estacionalidad se ve con más claridad (Figura 4.3): la autocorrelación en el rezago 12 es 0,83. Es decir, el cambio de un mes a otro se repite casi igual cada año.

# 5 Estacionalidad

La estacionalidad es un patrón que se repite cada cierto periodo fijo; en este caso, cada año.

# 5.1 Gráfico estacional

```
ggseasonplot(y, year.labels = TRUE) + labs(title = "", x = "Mes", y = "Índice")
```

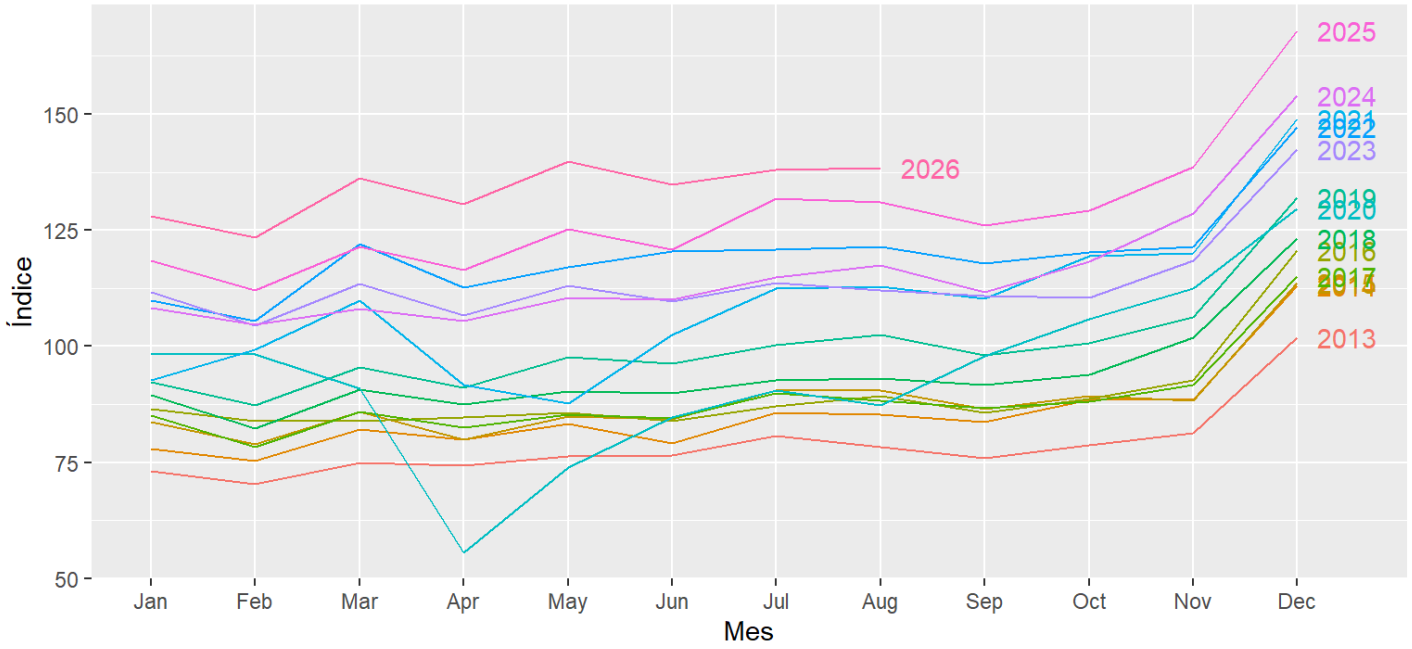



Figura 5.1: Índice por mes, una línea por año.

Todas las líneas de la Figura 5.1 tienen una forma parecida: febrero y abril son meses bajos, julio y agosto suben un poco, y diciembre es el mes más alto. La línea de 2020 es la única que se sale del patrón, con la caída de abril y mayo.

# 5.2 Subseries por mes

```
ggsubseriesplot(y) + labs(title = "", x = "Mes", y = "Índice")
```

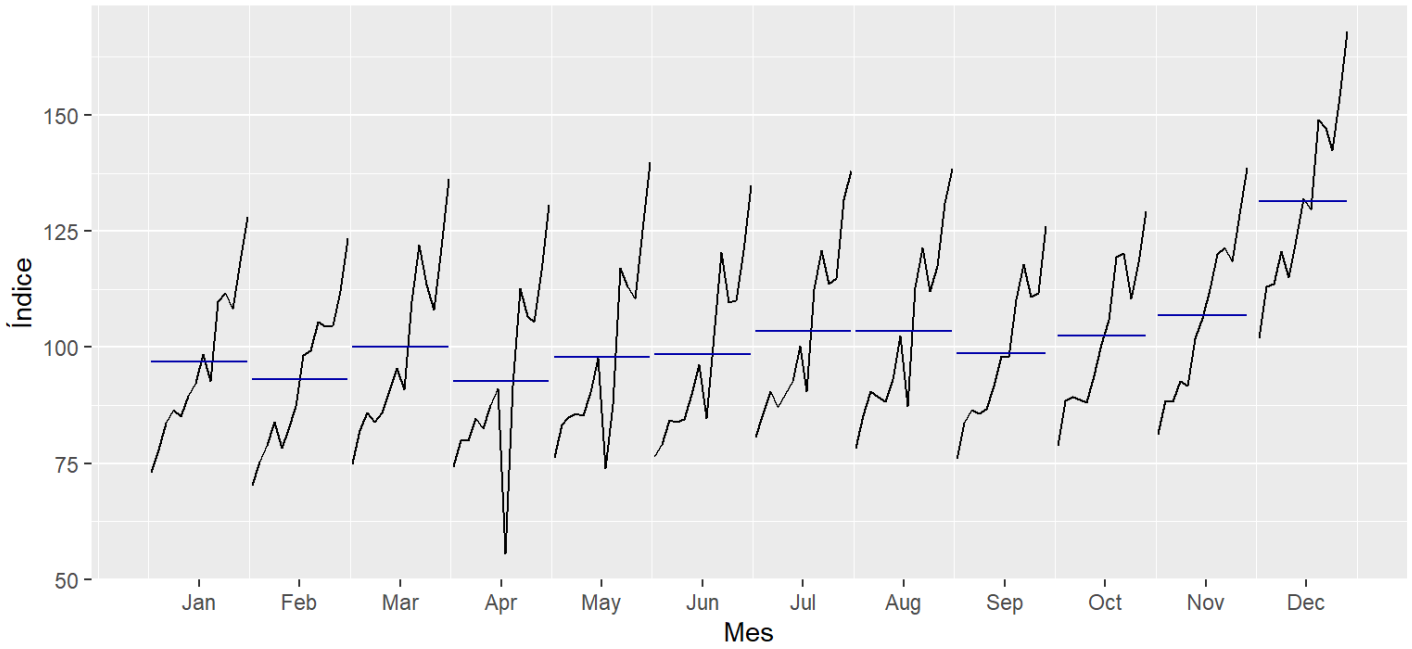



Figura 5.2: Evolución de cada mes a lo largo de los años. La línea horizontal es el promedio del mes.

La Figura 5.2 confirma que diciembre tiene un promedio muy por encima del resto y que todos los meses crecen con los años.

# 5.3 Descomposición

La descomposición separa la serie en tendencia, componente estacional y resto. Se usa la forma multiplicativa porque los picos de diciembre se hacen más grandes a medida que sube el nivel de la serie.

```
desc <- decompose(y, type = "multiplicative")
autoplot(desc) + labs(title = "", x = "Año")
```

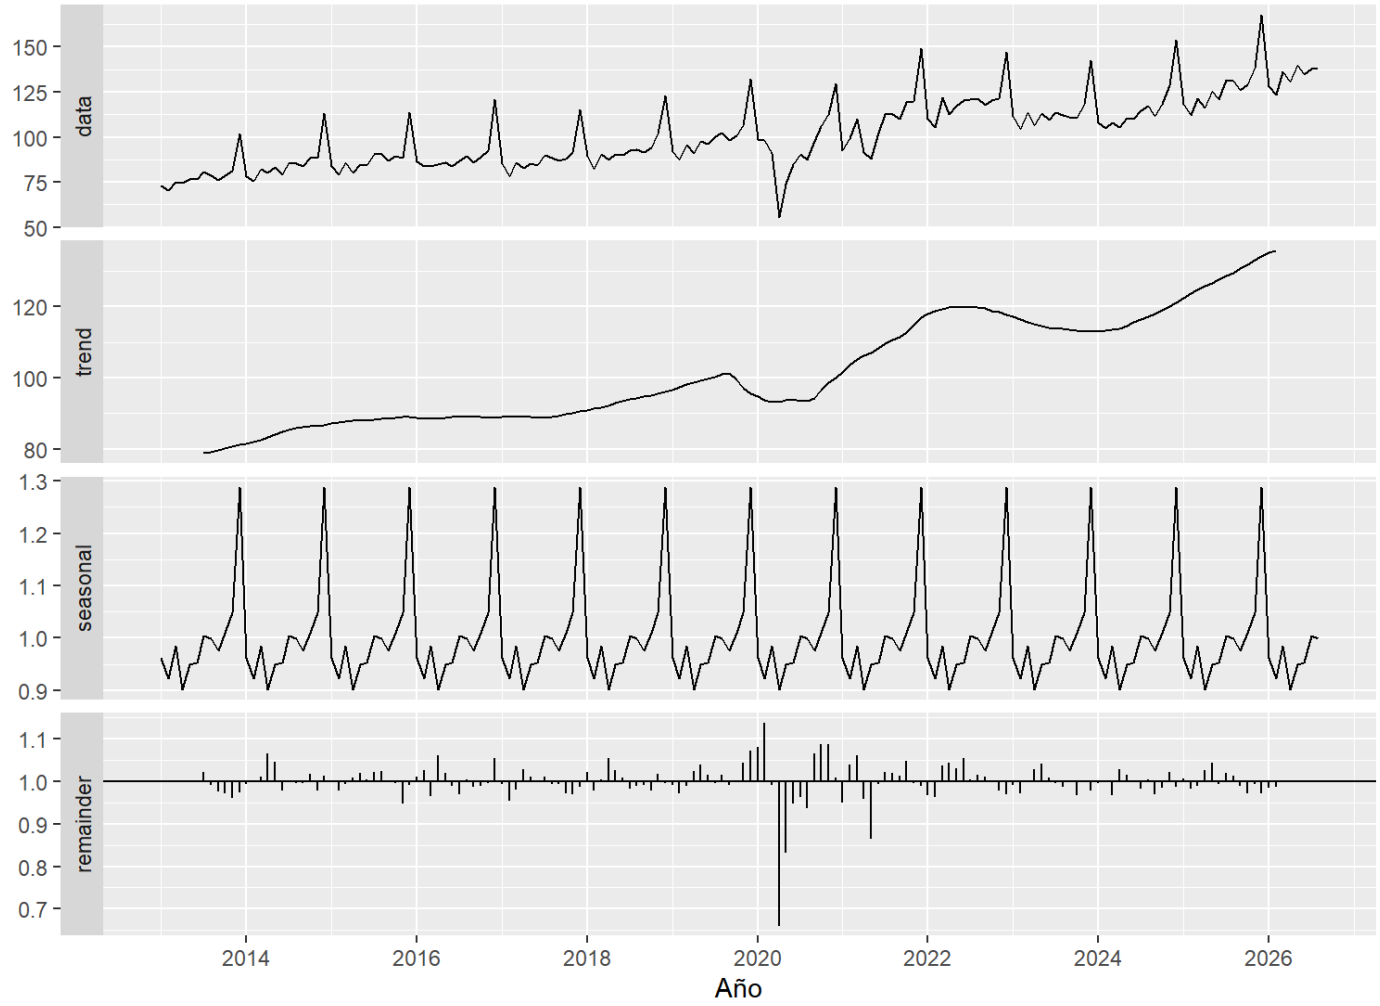



Figura 5.3: Descomposición multiplicativa del índice.

```
round(desc$figure, 3)
```

```
##  [1] 0.963 0.923 0.985 0.902 0.948 0.954 1.004 0.999 0.976 1.010 1.049 1.288
```

Los índices estacionales indican cuánto se aleja cada mes de la tendencia. Diciembre vende alrededor de 29 % más que la tendencia (1,288) y noviembre 5 % más (1,049). Los meses más bajos son abril (0,902) y febrero (0,923). El valor de abril sale más bajo por la caída de 2020, y también influye la Semana Santa, que suele caer en ese mes.

# 6 Transformación de la serie

A partir de este capítulo empieza la Unidad 3. La idea es dejar la serie lista para los modelos de pronóstico, y se hace en tres pasos:

1. Revisar si hace falta transformar la serie para controlar su variabilidad (este capítulo).
2. Descomponerla para ver con claridad qué tendencia y qué estacionalidad hay que controlar (capítulo 7).
3. Comprobar si es estacionaria y diferenciarla si no lo es (capítulo 8).

# 6.1 ¿Hace falta transformar?

En la Figura 2.1 se nota que los picos de diciembre son cada vez más altos: a medida que la serie crece, también crecen sus subidas y bajadas. Para comprobarlo se calcula, para cada año, el promedio del índice y su desviación estándar:

```
anio <- floor(time(y))
tabla <- data.frame(
  promedio   = tapply(y, anio, mean),
  desviacion = tapply(y, anio, sd),
  desv_log   = tapply(log(y), anio, sd)
)
round(tabla, 2)
```

```
##      promedio desviacion desv_log
## 2013    78.55       7.95     0.09
## 2014    85.23       9.67     0.10
## 2015    88.04       8.87     0.09
## 2016    89.42      10.20     0.10
## 2017    88.46       9.06     0.09
## 2018    93.90      10.27     0.10
## 2019   100.00      11.33     0.10
## 2020    93.82      18.66     0.21
## 2021   109.00      16.55     0.15
## 2022   119.73      10.13     0.08
## 2023   113.94       9.65     0.08
## 2024   116.00      13.64     0.11
## 2025   128.27      14.52     0.10
## 2026   133.69       5.76     0.04
```

La desviación estándar pasa de cerca de 8 en 2013 a más de 14 en 2025, es decir, la variabilidad crece con el nivel. Lo que se mantiene casi constante es la proporción: en casi todos los años la desviación es alrededor del 10 % del promedio. Cuando la variabilidad crece en proporción al nivel, la transformación indicada es el **logaritmo**.

La última columna lo confirma: con el logaritmo, la desviación queda cerca de 0,10 todos los años. Las excepciones son 2020 y 2021, que se alteran por la pandemia y no por el nivel de la serie, y 2026, que solo tiene ocho meses y no incluye diciembre.

# 6.2 ¿Por qué logaritmo y no otra transformación?

La transformación de Box-Cox incluye al logaritmo como caso particular, y la función `BoxCox.lambda()` sugiere un valor para su parámetro:

```
BoxCox.lambda(y)
```

```
## [1] 0.8312108
```

El valor sugerido está entre 1 (no transformar) y 0 (logaritmo). Se prefiere el logaritmo por dos razones prácticas: la tabla anterior muestra que estabiliza bien la variabilidad, y sus resultados son fáciles de interpretar, porque una diferencia en logaritmos equivale, aproximadamente, a una variación porcentual.

```
ly <- log(y)
autoplot(ly) + labs(x = "Año", y = "log(índice)")
```

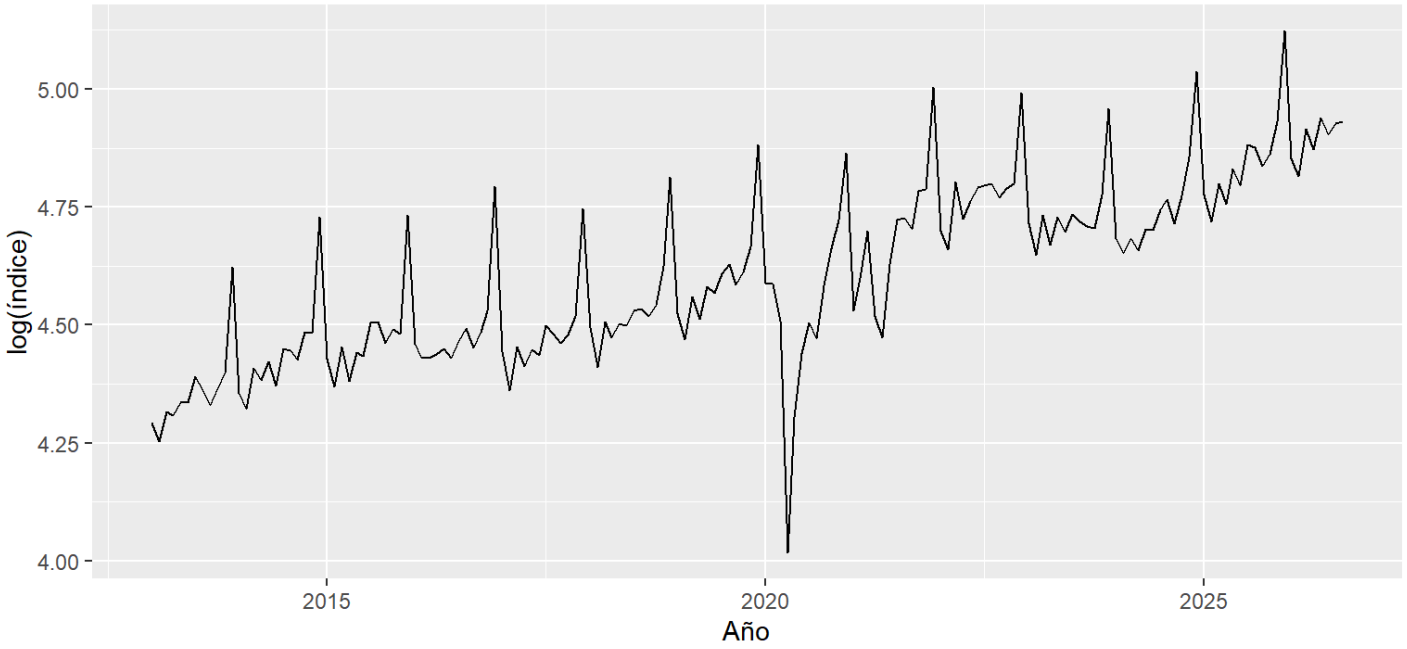



Figura 6.1: Logaritmo del índice de ventas reales.

En la Figura 6.1 los picos de diciembre tienen un tamaño parecido al principio y al final de la serie. La transformación controla la variabilidad, pero no quita la tendencia: la serie sigue subiendo. Eso se trata con la diferenciación en el capítulo 8.

# 7 Descomposición

En la Unidad 2 se hizo una descomposición multiplicativa de la serie original. Ahora se descompone el logaritmo, y al trabajar en logaritmos la descomposición pasa a ser aditiva:

$$\log(y_t) = \text{tendencia}_t + \text{estacionalidad}_t + \text{resto}_t$$

Se usa el método STL, que estima cada componente con suavizamientos locales. Con la opción `robust = TRUE`, los meses atípicos de 2020 pesan menos y no deforman la tendencia ni la estacionalidad.

```
desc_log <- stl(ly, s.window = "periodic", robust = TRUE)
autoplot(desc_log) + labs(x = "Año")
```

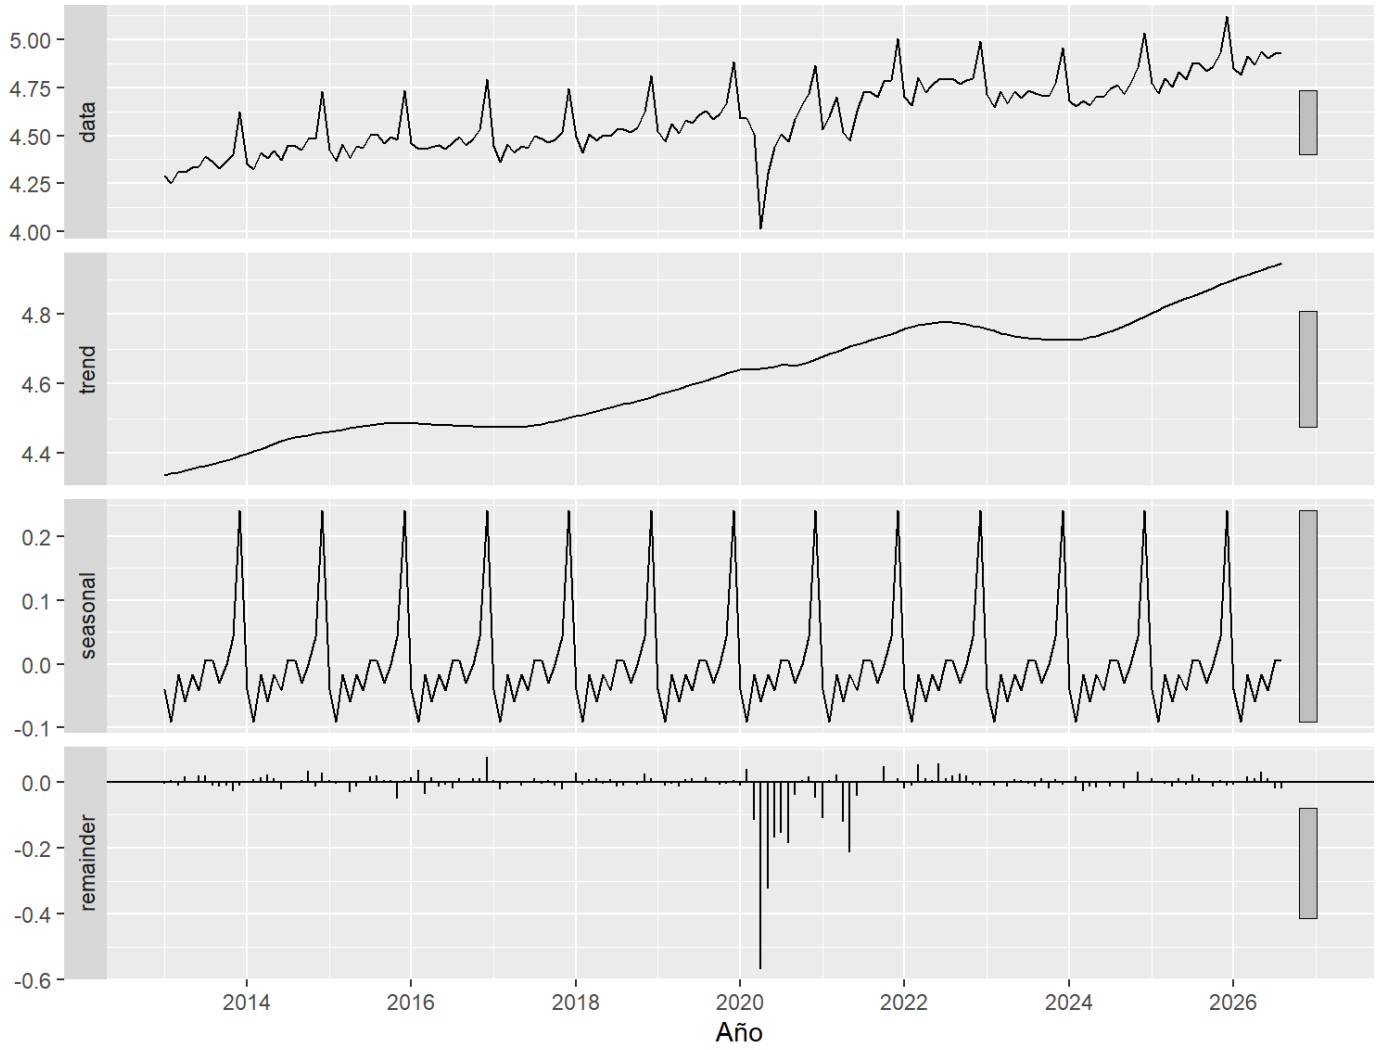



Figura 7.1: Descomposición STL del logaritmo del índice.

La Figura 7.1 muestra tres cosas:

- **Tendencia:** sube durante casi todo el periodo. En 2020 solo se aplana, porque la caída de la pandemia queda en el resto, y en 2023 baja un poco antes de volver a subir. Que la serie tenga tendencia significa que su promedio cambia con el tiempo.
- **Estacionalidad:** es la misma todos los años, con diciembre muy por encima de los demás meses. Es un patrón fuerte y estable.

- **Resto:** se mantiene cerca de cero, salvo en 2020 y 2021, cuando la pandemia sacó la serie de su comportamiento normal.

La descomposición deja claro qué hay que controlar antes de modelar: la tendencia y la estacionalidad. Mientras estén presentes, la serie no puede ser estacionaria, y eso es lo que se comprueba en el siguiente capítulo.

# 8 Estacionariedad y diferenciación

Una serie es estacionaria cuando su promedio y su variabilidad no cambian con el tiempo y no tiene patrones que se repitan de forma fija. Modelos como ARIMA necesitan trabajar sobre una serie estacionaria, así que hay que comprobar si esta lo es.

Cuando una serie no es estacionaria, la forma más común de corregirla es **diferenciarla**, es decir, trabajar con los cambios en lugar de los niveles:

- **Diferencia regular:** el cambio frente al mes anterior, $y_t - y_{t-1}$. Quita la tendencia.
- **Diferencia estacional:** el cambio frente al mismo mes del año anterior, $y_t - y_{t-12}$. Quita la estacionalidad.

# 8.1 Cómo se comprueba

Además de revisar los gráficos y la ACF, se usan dos pruebas estadísticas del paquete `tseries`, que se complementan porque parten de hipótesis opuestas:

- **Prueba ADF (Dickey-Fuller aumentada):** su hipótesis nula es que la serie *no* es estacionaria. Un valor p menor a 0,05 indica que sí lo es.
- **Prueba KPSS:** su hipótesis nula es que la serie *sí* es estacionaria. Un valor p menor a 0,05 indica que no lo es.

Se toma una serie como estacionaria cuando las dos pruebas coinciden. Para no repetir código, se crea una función pequeña que devuelve los dos valores p:

```
library(tseries)
pruebas <- function(x) {
  c(ADF = adf.test(x)$p.value, KPSS = kpss.test(x)$p.value)
}
```

Las funciones de `tseries` reportan los valores p dentro de un rango, así que un 0,01 significa “0,01 o menos” y un 0,10 significa “0,10 o más”.

# 8.2 Paso 1: la serie en logaritmos

```
round(pruebas(ly), 3)
```

```
##  ADF KPSS
## 0.01 0.01
```

La KPSS da un valor p menor a 0,05, así que la serie **no es estacionaria**, como ya se veía en la tendencia de la Figura 7.1. La ADF da un resultado contrario, pero no es confiable en este caso: los picos de diciembre se repiten de forma tan regular que la prueba los confunde con una serie que vuelve siempre a su promedio. El gráfico, la descomposición y la ACF de la Unidad 2, que bajaba muy lento, coinciden en que hay tendencia.

# 8.3 Paso 2: diferencia estacional

Como la estacionalidad es el patrón más fuerte, se aplica primero la diferencia de 12 meses. La serie resultante es, en la práctica, la tasa de crecimiento anual del índice:

```
d12 <- diff(ly, lag = 12)
round(pruebas(d12), 3)
```

```
##  ADF KPSS
## 0.07 0.10
```

La estacionalidad desaparece, pero el resultado todavía no es claro: la KPSS acepta que la serie es estacionaria, mientras que la ADF da 0,07 y no alcanza a confirmarlo. Además, su ACF baja lentamente, señal de que queda algo de tendencia:

```
ggAcf(d12, lag.max = 36) + labs(title = "")
```

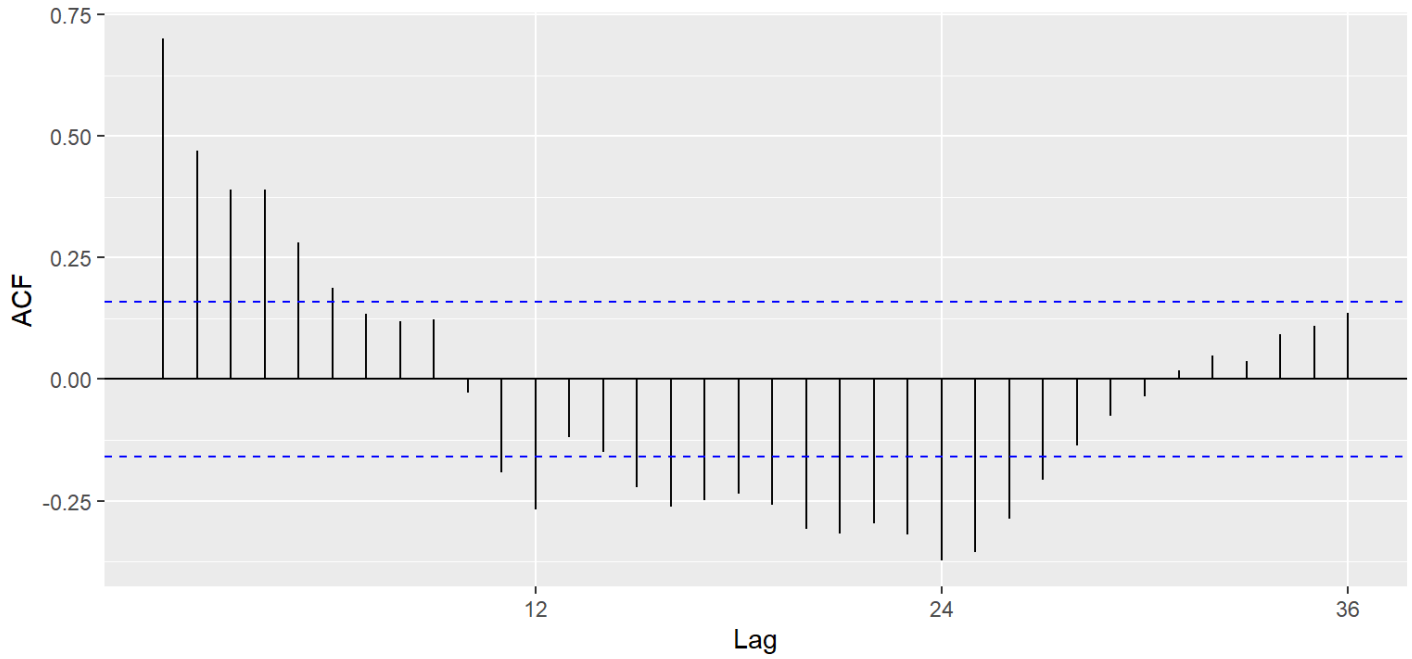



Figura 8.1: ACF de la serie con diferencia estacional.

# 8.4 Paso 3: diferencia regular

Para quitar la tendencia que queda se aplica una diferencia regular a la serie del paso 2:

```
dd <- diff(d12)
round(pruebas(dd), 3)
```

```
##  ADF KPSS
## 0.01 0.10
```

Ahora las dos pruebas coinciden: la ADF rechaza que la serie no sea estacionaria (valor p de 0,01) y la KPSS no rechaza que lo sea (0,10). La serie **ya es estacionaria**. La función `nsdiffs()` de `forecast` coincide en que se necesita una diferencia estacional:

```
nsdiffs(ly)
```

```
## [1] 1
```

```
autoplot(cbind("Logaritmo" = ly,
               "Diferencia estacional" = d12,
               "Diferencias estacional y regular" = dd), facets = TRUE) +
  labs(x = "Año", y = "")
```

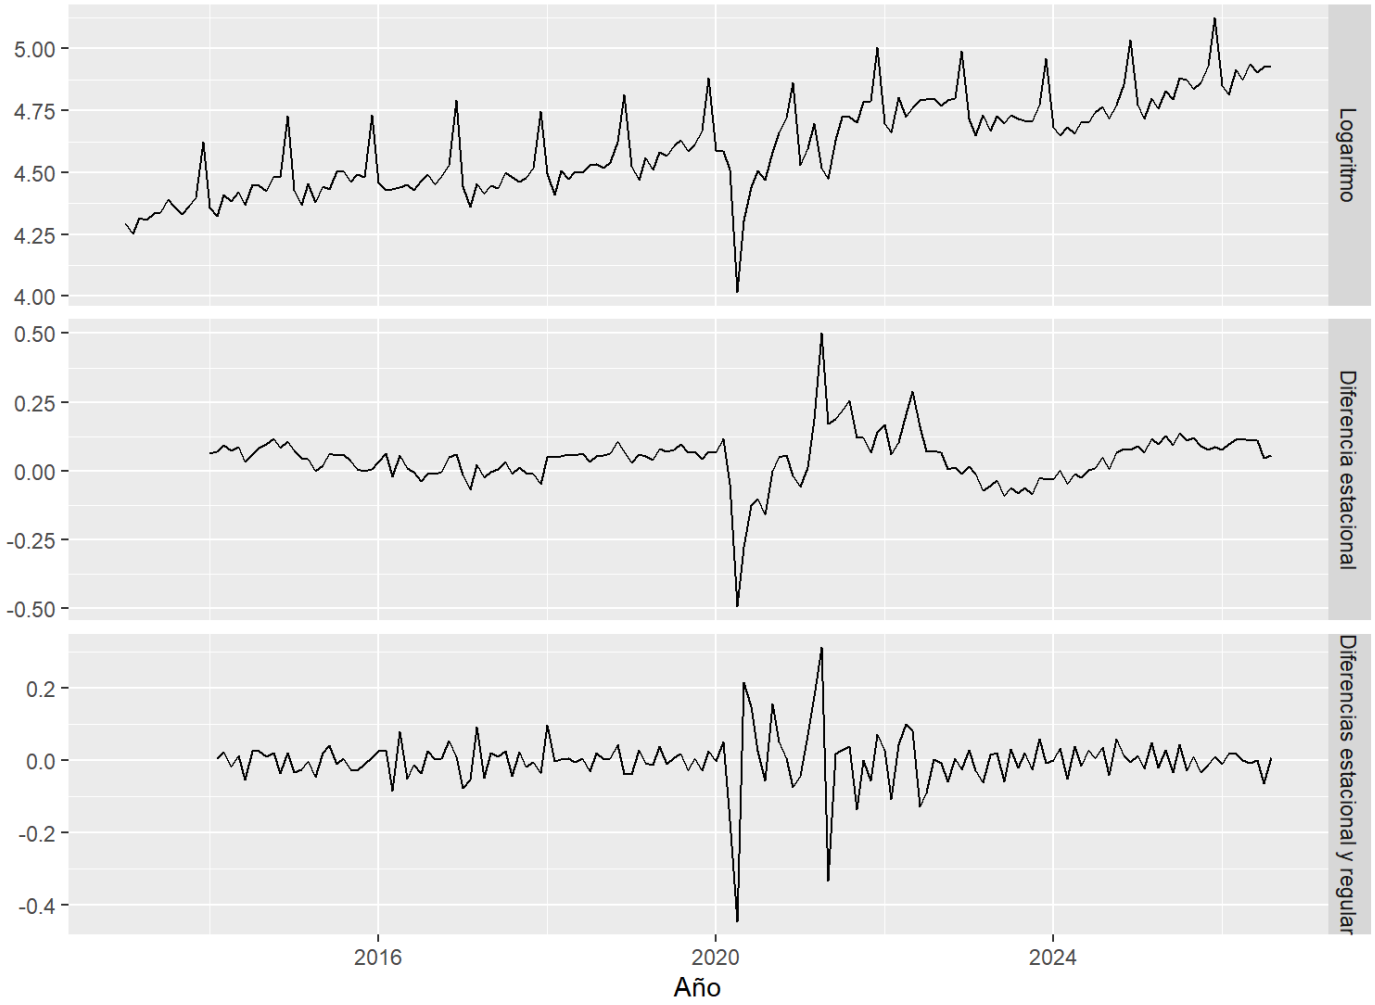



Figura 8.2: La serie en cada paso: logaritmo, con diferencia estacional y con las dos diferencias.

En la Figura 8.2 se ve el efecto de cada paso: la serie en logaritmos sube y tiene picos cada diciembre; con la diferencia estacional desaparecen los picos, pero la serie todavía se mueve por rachas; con las dos diferencias queda oscilando alrededor de cero, con una variabilidad parecida en todo el periodo. Solo 2020 y 2021 se salen de ese comportamiento por la pandemia.

```
ggAcf(dd, lag.max = 36) + labs(title = "")
```

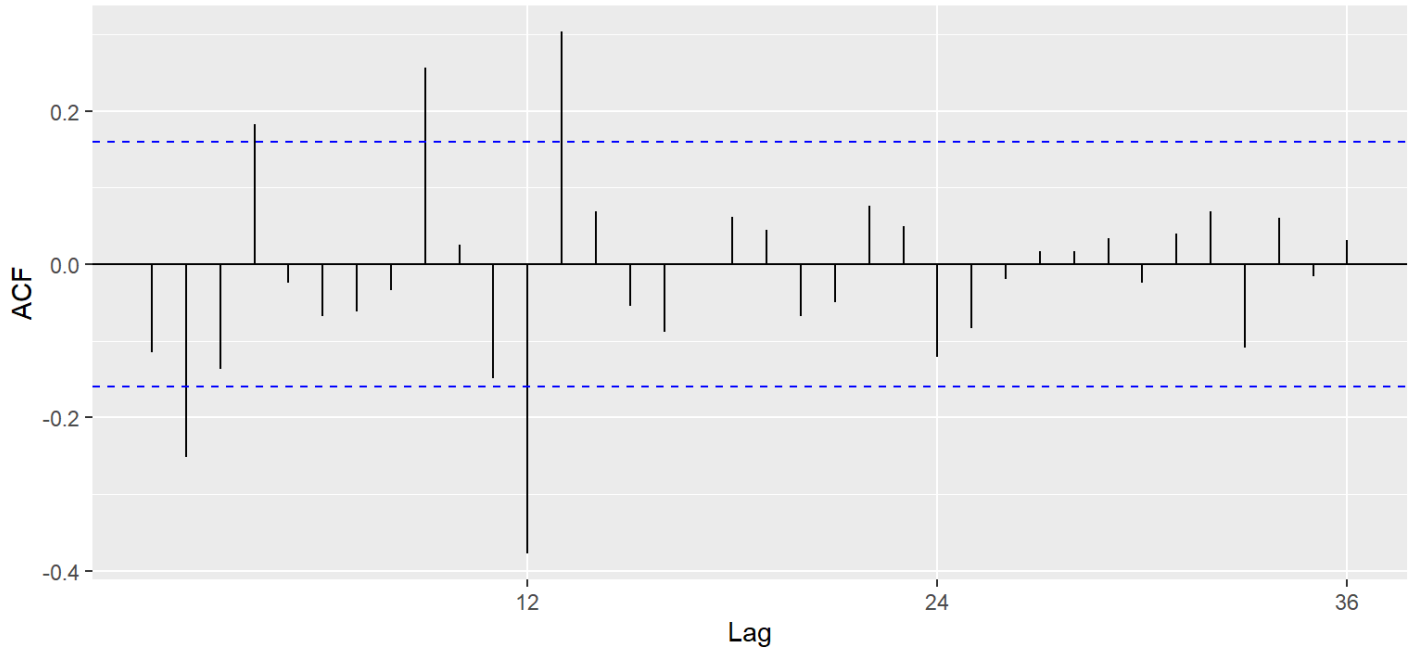



Figura 8.3: ACF de la serie con las dos diferencias.

La ACF de la Figura 8.3 ya no baja lentamente: la mayoría de las barras están dentro de las bandas. Sobresale el rezago 12 y, en menor medida, algunos rezagos cortos (2, 9 y 13). El rezago 12 muestra que todavía queda una relación con el mismo mes del año anterior. Esa relación es la que deberá recoger el modelo ARIMA estacional en la siguiente unidad.

# 8.5 Resumen del procedimiento

| Paso | Procedimiento | ¿Era necesario? | Por qué |
|---|---|---|---|
| 1 | Logaritmo | Sí | La variabilidad crecía con el nivel de la serie |
| 2 | Diferencia estacional (12 meses) | Sí | La estacionalidad anual es fuerte y estable |
| 3 | Diferencia regular (1 mes) | Sí | Después del paso 2 quedaba tendencia y las pruebas no coincidían |

No se aplicó una segunda diferencia regular: con una sola, las pruebas ya coinciden en que la serie es estacionaria, y diferenciar de más agrega ruido sin necesidad.

# 9 Suavizamiento exponencial y Holt-Winters

A partir de este capítulo empieza la Unidad 4 y, con ella, los pronósticos. El promedio móvil del capítulo 3 le da el mismo peso a todos los meses que promedia. El **suavizamiento exponencial** también promedia el pasado, pero da más peso a los meses recientes y cada vez menos a los antiguos.

Hay tres versiones, y cada una agrega un componente de la serie:

| Método | Qué sigue | Parámetro que lo controla |
|---|---|---|
| Suavizamiento simple | Solo el nivel | $\alpha$ (nivel) |
| Holt | Nivel y tendencia | $\alpha$ y $\beta$ (tendencia) |
| Holt-Winters | Nivel, tendencia y estacionalidad | $\alpha$, $\beta$ y $\gamma$ (estacionalidad) |

Los parámetros van de 0 a 1. Cerca de 1, el modelo se ajusta rápido a lo último que pasó. Cerca de 0, el componente casi no cambia en el tiempo. R los estima solo, buscando los valores que mejor reproducen la serie.

Holt-Winters puede tratar la estacionalidad de dos formas. En la **aditiva**, el pico de diciembre suma siempre más o menos lo mismo. En la **multiplicativa**, el pico crece con el nivel de la serie. En el capítulo 6 se vio que esta serie se comporta como el segundo caso. Por eso también se prueba Holt-Winters aditivo sobre el logaritmo, que equivale a una estacionalidad proporcional.

# 9.1 Procedimiento

1. Separar la serie en un periodo de entrenamiento y uno de prueba.
2. Ajustar los modelos con el periodo de entrenamiento y pronosticar el periodo de prueba.
3. Comparar los pronósticos con los datos reales y elegir el modelo con menor error.
4. Volver a ajustar el modelo elegido con toda la serie y pronosticar los siguientes 12 meses.

# 9.2 Entrenamiento y prueba

Se guardan los últimos 12 meses (septiembre de 2025 a agosto de 2026) como prueba. Así la evaluación cubre un año completo, incluido diciembre, el mes más difícil de pronosticar.

```
train <- window(y, end = c(2025, 8))
test  <- window(y, start = c(2025, 9))
h <- length(test)
```

# 9.3 Modelos

Se ajustan cinco modelos de suavizamiento. Como punto de comparación se agrega el modelo ingenuo estacional de la propuesta, que pronostica cada mes con el valor del mismo mes del año anterior.

```
modelos <- list(
  "Simple"                  = ses(train, h = h),
  "Holt"                    = holt(train, h = h),
  "Holt-Winters aditivo"    = hw(train, h = h, seasonal = "additive"),
  "Holt-Winters multiplic." = hw(train, h = h, seasonal = "multiplicative"),
  "Holt-Winters sobre log"  = hw(train, h = h, seasonal = "additive", lambda = 0),
  "Ingenuo estacional"      = snaive(train, h = h)
)
```

# 9.4 Comparación

Cada pronóstico se compara con los datos reales de la prueba usando dos medidas de error: el RMSE, en puntos del índice, y el MAPE, que es el error promedio en porcentaje.

```
errores <- t(sapply(modelos, function(m) accuracy(m, test)["Test set", c("RMSE", "MAPE")]))
knitr::kable(errores[order(errores[, "RMSE"]), ], digits = 2,
             caption = "Error de cada modelo en el periodo de prueba.")
```

Tabla 9.1: Error de cada modelo en el periodo de prueba.

| | RMSE | MAPE |
|---|---|---|
| Holt-Winters sobre log | 4.64 | 2.45 |
| Holt-Winters aditivo | 5.12 | 3.08 |
| Holt-Winters multiplic. | 5.43 | 3.13 |
| Ingenuo estacional | 12.14 | 8.72 |
| Holt | 13.82 | 6.19 |
| Simple | 15.15 | 7.42 |

```
autoplot(window(y, start = 2022), series = "Real") +
  autolayer(modelos[["Holt-Winters aditivo"]]$mean, series = "HW aditivo") +
  autolayer(modelos[["Holt-Winters multiplic."]]$mean, series = "HW multiplicativo") +
  autolayer(modelos[["Holt-Winters sobre log"]]$mean, series = "HW sobre log") +
  scale_colour_manual(values = c(Real = "black", "HW aditivo" = "orange",
                                 "HW multiplicativo" = "steelblue", "HW sobre log" = "darkred"))
+
  labs(x = "Año", y = "Índice", colour = "")
```

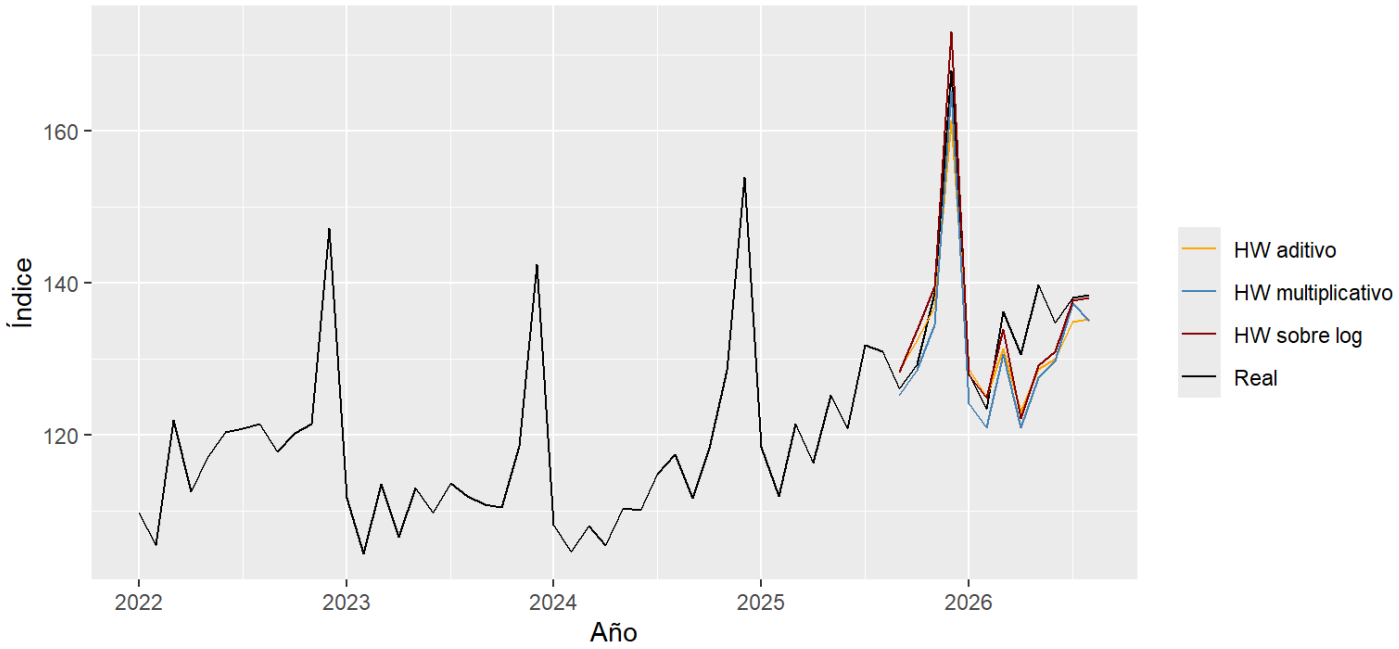



Figura 9.1: Pronósticos de los tres modelos Holt-Winters en el periodo de prueba.

La Tabla 9.1 muestra tres grupos:

- **Simple y Holt** fallan por mucho (MAPE de 7,4 % y 6,2 %). No tienen estacionalidad, así que pronostican una línea casi recta y no ven el pico de diciembre.
- **El ingenuo estacional** también queda lejos (8,7 %), porque repite el año anterior y no recoge el crecimiento de la serie.
- **Los tres Holt-Winters** bajan el error a cerca del 3 %. La diferencia la hace la estacionalidad.

El mejor es **Holt-Winters sobre el logaritmo**, con un MAPE de 2,45 %. En la Figura 9.1 es el que mejor acierta el pico de diciembre de 2025. Los otros dos se quedan cortos. Los tres fallan de forma parecida entre abril y mayo de 2026, cuando las ventas subieron más de lo que mostraba su historia.

# 9.5 Modelo elegido

Se vuelve a ajustar Holt-Winters sobre el logaritmo, ahora con toda la serie, y se pronostican los siguientes 12 meses:

```
final <- hw(y, h = 12, seasonal = "additive", lambda = 0)
round(final$model$par[c("alpha", "beta", "gamma")], 3)
```

```
## alpha  beta gamma
## 0.698 0.001 0.000
```

Los parámetros se leen así:

- $\alpha$ **alto:** el nivel se ajusta rápido a los últimos meses.
- $\beta$ **y** $\gamma$ **casi en cero:** el ritmo de crecimiento y el patrón de cada mes casi no cambian en el tiempo. Esto coincide con la descomposición del capítulo 7, que mostró una tendencia constante y una estacionalidad estable.

# 9.6 Pronóstico

```
autoplot(final, include = 60) + labs(title = "", x = "Año", y = "Índice")
```

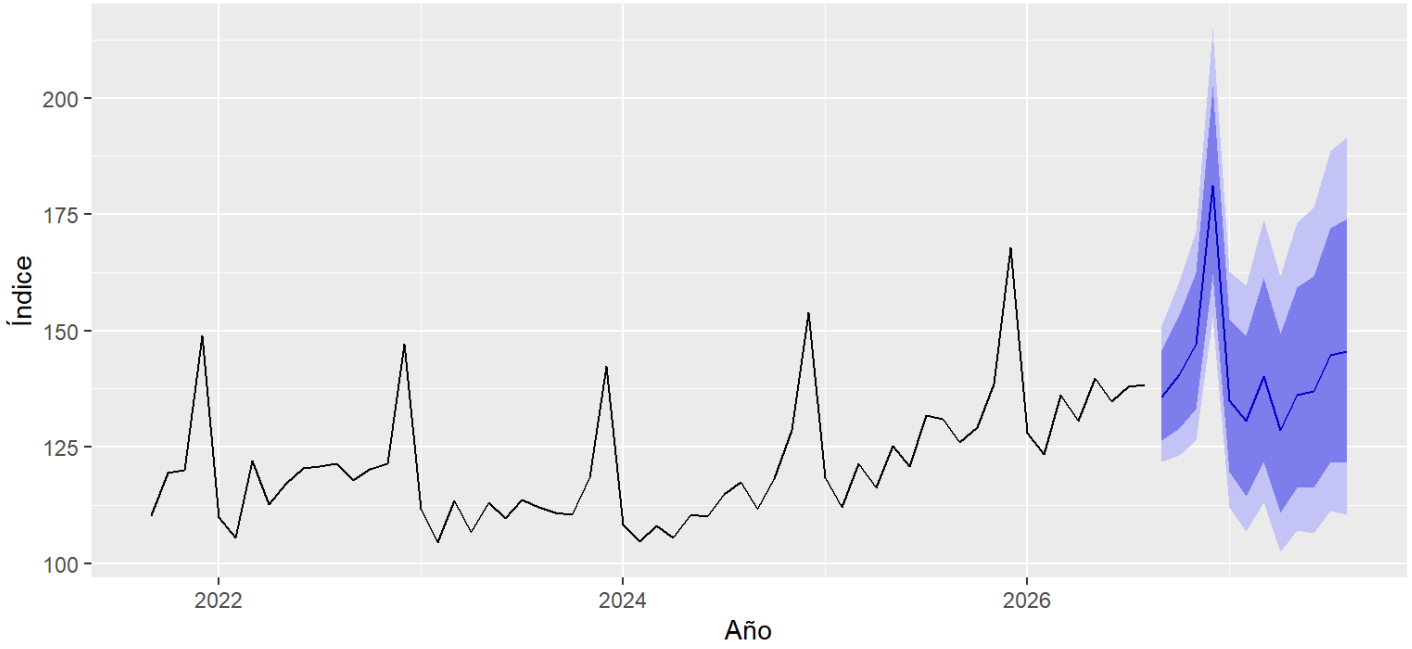



Figura 9.2: Pronóstico de septiembre de 2026 a agosto de 2027 con intervalos de 80 % y 95 %.

```
knitr::kable(as.data.frame(final), digits = 1,
             col.names = c("Pronóstico", "Inf. 80 %", "Sup. 80 %", "Inf. 95 %", "Sup. 95 %"),
             caption = "Pronóstico del índice de ventas reales (2019 = 100).")
```

Tabla 9.2: Pronóstico del índice de ventas reales (2019 = 100).

| | Pronóstico | Inf. 80 % | Sup. 80 % | Inf. 95 % | Sup. 95 % |
|---|---|---|---|---|---|
| Sep 2026 | 135.7 | 126.5 | 145.7 | 121.8 | 151.2 |
| Oct 2026 | 140.7 | 129.0 | 153.3 | 123.3 | 160.5 |
| Nov 2026 | 147.2 | 133.3 | 162.6 | 126.4 | 171.3 |
| Dec 2026 | 181.2 | 162.1 | 202.4 | 152.9 | 214.7 |
| Jan 2027 | 135.0 | 119.5 | 152.5 | 112.1 | 162.6 |
| Feb 2027 | 130.6 | 114.5 | 149.0 | 106.9 | 159.7 |
| Mar 2027 | 140.2 | 121.8 | 161.3 | 113.1 | 173.8 |
| Apr 2027 | 128.7 | 110.9 | 149.4 | 102.5 | 161.7 |
| May 2027 | 136.1 | 116.3 | 159.3 | 107.0 | 173.1 |
| Jun 2027 | 137.0 | 116.2 | 161.6 | 106.5 | 176.4 |
| Jul 2027 | 144.8 | 121.9 | 172.1 | 111.3 | 188.5 |

| | Pronóstico | Inf. 80 % | Sup. 80 % | Inf. 95 % | Sup. 95 % |
|---|---|---|---|---|---|
| Aug 2027 | 145.5 | 121.6 | 174.1 | 110.5 | 191.5 |

El modelo espera que el índice siga creciendo. El pico de diciembre de 2026 queda alrededor de 181 y en agosto de 2027 el índice llegaría a cerca de 145, un 5 % más que en agosto de 2026. Los intervalos se abren a medida que el pronóstico se aleja, porque la incertidumbre se acumula mes a mes.

El modelo supone que la tendencia y la estacionalidad de los últimos años se mantienen. Si llega un choque como el de 2020 o una desaceleración como la de 2023, el pronóstico no lo va a anticipar.

# 10 Conclusiones

**Unidad 2**

- El promedio móvil de orden 12 elimina la estacionalidad y deja ver una tendencia creciente, con una caída en 2020 por la pandemia y otra en 2023.
- Los rezagos muestran que el índice depende mucho de sus valores pasados, sobre todo del mismo mes del año anterior (rezago 12).
- La estacionalidad es anual y estable: diciembre es el mes más alto y febrero y abril los más bajos.

**Unidad 3**

- La variabilidad de la serie crece con su nivel, por eso se trabajó con el logaritmo.
- La descomposición STL confirma una tendencia creciente y una estacionalidad estable, y deja los efectos de la pandemia en el componente de resto.
- La serie en logaritmos no es estacionaria. Necesita una diferencia estacional y una regular; después de las dos, las pruebas ADF y KPSS coinciden en que es estacionaria.

**Unidad 4**

- Los métodos sin estacionalidad (suavizamiento simple y Holt) no sirven para esta serie: no ven el pico de diciembre y su error en la prueba pasa del 6 %.
- Holt-Winters baja el error a cerca del 3 %. El mejor modelo es Holt-Winters sobre el logaritmo, con un MAPE de 2,45 %. Esto confirma que trabajar en logaritmos, como se decidió en la Unidad 3, también mejora el pronóstico.
- El modelo proyecta que el índice siga creciendo hasta agosto de 2027, con el pico usual en diciembre de 2026.

Lo que sigue es ajustar un modelo ARIMA estacional sobre el logaritmo con $d = 1$ y $D = 1$, como se concluyó en la Unidad 3, y compararlo con Holt-Winters sobre el mismo periodo de prueba.

# Fuentes


- DANE. Encuesta Mensual de Comercio (EMC). Anexo de índices empalmados, agosto de 2026 (actualizado el 16 de octubre de 2026, consultado el 25 de octubre de 2026). https://www.dane.gov.co/files/operaciones/EMC/anex-EMC-SeriesIndiceEmpalmados-ago2026.xlsx (https://www.dane.gov.co/files/operaciones/EMC/anex-EMC-SeriesIndiceEmpalmados-ago2026.xlsx)
- DANE. Encuesta Mensual de Comercio (EMC). https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc (https://www.dane.gov.co/index.php/estadisticas-por-tema/comercio-interno/encuesta-mensual-de-comercio-emc)
- DANE. Metodología general de la EMC. https://www.dane.gov.co/files/operaciones/EMC/met-EMC.pdf (https://www.dane.gov.co/files/operaciones/EMC/met-EMC.pdf)
- DANE. Términos y condiciones del portal. https://www.dane.gov.co/index.php/terminos-y-condiciones (https://www.dane.gov.co/index.php/terminos-y-condiciones)
- Holt, C. C. (2004). Forecasting seasonals and trends by exponentially weighted moving averages. *International Journal of Forecasting*, 20(1), 5-10. https://doi.org/10.1016/j.ijforecast.2003.09.015 (https://doi.org/10.1016/j.ijforecast.2003.09.015)
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/ (https://otexts.com/fpp3/)
- Hyndman, R. J. y Khandakar, Y. (2008). Automatic time series forecasting: the forecast package for R. *Journal of Statistical Software*, 27(3), 1-22. https://doi.org/10.18637/jss.v027.i03 (https://doi.org/10.18637/jss.v027.i03)
- Trapletti, A. y Hornik, K. *tseries: Time Series Analysis and Computational Finance* (paquete de R). https://CRAN.R-project.org/package=tseries (https://CRAN.R-project.org/package=tseries)
- Winters, P. R. (1960). Forecasting sales by exponentially weighted moving averages. *Management Science*, 6(3), 324-342. https://doi.org/10.1287/mnsc.6.3.324 (https://doi.org/10.1287/mnsc.6.3.324)
- Xie, Y. (2016). *bookdown: Authoring Books and Technical Documents with R Markdown*. Chapman and Hall/CRC.


Fuente de los datos: Departamento Administrativo Nacional de Estadística: www.dane.gov.co